

**APLICACIÓN DE REGRESIÓN LINEAL MÚLTIPLE BAJO LA METODOLOGÍA
CRISP-DM PARA LA PREDICCIÓN DEL PRECIO DEL DÓLAR, EL NIVEL DE
GLUCOSA EN SANGRE Y EL CONSUMO DE ENERGÍA ELÉCTRICA**

Valery Nickol Rosero Molina

Facultad de Ingeniería, Programa de Ingeniería de Software

Universidad Cooperativa de Colombia

Inteligencia de Negocios y Minería de Datos

Docente: Dr. Cristian Camilo Ordoñez Quintero

San Juan de Pasto, Colombia

28 de septiembre de 2026

Resumen

El presente informe documenta la aplicación de la metodología CRISP-DM (Cross Industry Standard Process for Data Mining) para el desarrollo de tres modelos de regresión lineal múltiple orientados a la predicción del precio del dólar, el nivel de glucosa en sangre y el consumo de energía eléctrica. Se describen las fases de comprensión de los datos, preparación, modelado y evaluación, esta última basada en el error cuadrático medio (MSE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2), calculados tanto en el conjunto de entrenamiento como en el de prueba, además de validación cruzada de cinco particiones (5-fold), con el fin de descartar sobreajuste. Los tres modelos alcanzaron un R^2 superior al 90% en el conjunto de prueba, con diferencias inferiores al 2% frente al conjunto de entrenamiento. Finalmente, se exportaron los modelos mediante la librería joblib y se integraron en una interfaz web desarrollada con Streamlit para su uso interactivo.

Palabras clave: minería de datos, regresión lineal múltiple, CRISP-DM, aprendizaje automático, evaluación de modelos.

1. Introducción

La minería de datos comprende un conjunto de técnicas orientadas a descubrir patrones, relaciones y modelos predictivos a partir de conjuntos de datos estructurados. Entre las técnicas de modelado predictivo más utilizadas se encuentra la regresión lineal múltiple, la cual permite estimar el valor de una variable cuantitativa dependiente a partir de dos o más variables independientes, asumiendo una relación lineal entre ellas (Montgomery et al., 2021). El objetivo del presente laboratorio es aplicar las fases de la metodología CRISP-DM (Chapman et al., 2000) para construir, evaluar, exportar y desplegar tres modelos de regresión lineal múltiple en distintos contextos: económico (precio del dólar), clínico (nivel de glucosa en sangre) e industrial/energético (consumo de energía eléctrica).

2. Metodología

El desarrollo del laboratorio se estructuró siguiendo las fases del modelo CRISP-DM (Chapman et al., 2000), tal como se resume en la Tabla 1.

Fase CRISP-DM	Aplicación en el laboratorio
Comprensión del negocio	Predecir el comportamiento de tres variables de interés (precio del dólar, glucosa y consumo eléctrico) a partir de variables explicativas disponibles.
Comprensión de los datos	Exploración de los conjuntos de datos mediante estadística descriptiva y matrices de correlación.
Preparación de los datos	Selección de variables independientes y dependiente; partición en entrenamiento (80%) y prueba (20%).
Modelado	Ajuste de un modelo de regresión lineal múltiple (scikit-learn) por cada ejercicio (Pedregosa et al., 2011).
Evaluación	Cálculo de MSE, RMSE y R^2 en entrenamiento y prueba, y validación cruzada de 5 particiones para descartar sobreajuste.
Despliegue	Exportación de los modelos con joblib e integración en una interfaz web desarrollada con Streamlit.

Tabla 1

Fases de la metodología CRISP-DM aplicadas en el laboratorio

Para determinar si un modelo presenta sobreajuste se comparó el coeficiente de determinación (R^2) obtenido en el conjunto de entrenamiento frente al obtenido en el conjunto de prueba, y frente al promedio de una validación cruzada de cinco particiones con barajado aleatorio de los datos. Se consideró que un modelo no presenta sobreajuste significativo cuando la diferencia entre el R^2 de entrenamiento y el de prueba es inferior a 0.05, y el R^2 de validación cruzada es consistente con ambos valores.

3. Predicción del precio del dólar

Se ajustó un modelo de regresión lineal múltiple utilizando las variables independientes Día, Inflación y Tasa de interés para predecir la variable Precio_Dolar. La ecuación del modelo

resultante es la siguiente:

$$\text{Precio_Dolar} = 3989.85 + 1.18 \cdot \text{Día} + 139.87 \cdot \text{Inflación} - 72.74 \cdot \text{Tasa_interes}$$

3.1 Interpretación de coeficientes

El coeficiente de la variable Día (+1.18) indica una tendencia de largo plazo al alza del precio del dólar. La variable Inflación (+139.87) presenta el mayor efecto marginal: por cada punto porcentual adicional de inflación, el precio del dólar aumenta en promedio 139.87 unidades, manteniendo las demás variables constantes. Por su parte, la Tasa de interés (−72.74) tiene un efecto inverso, consistente con la teoría económica según la cual tasas de interés más altas atraen capital extranjero y fortalecen la moneda local.

3.2 Desempeño del modelo

Conjunto	MSE	RMSE	R ²
Entrenamiento	6148.51	78.41	0.9304
Prueba	6604.58	81.27	0.9132
Validación cruzada (5-fold)	—	—	0.9249 ± 0.0132

Tabla 5
Métricas de desempeño del modelo de Precio_Dolar

La diferencia entre el R² de entrenamiento y de prueba fue de 0.0172, valor inferior al umbral de 0.05 establecido como criterio de sobreajuste, y el R² obtenido en la validación cruzada resultó consistente con ambos conjuntos. En consecuencia, el modelo generaliza adecuadamente y no presenta evidencia de sobreajuste, superando el umbral de R² > 0.90 exigido para el conjunto de prueba.

3.3 Visualización de relaciones entre variables

Figura 1
Relación de cada variable independiente con Precio_Dolar





Figura 2
Matriz de correlación — Predicción del precio del dólar



4. Predicción de niveles de glucosa en sangre

Se ajustó un modelo de regresión lineal múltiple utilizando las variables independientes Edad, IMC y Actividad física para predecir la variable Nivel_Glucosa. La ecuación del modelo resultante es la siguiente:

$$\text{Nivel_Glucosa} = 55.86 + 0.52 \cdot \text{Edad} + 1.92 \cdot \text{IMC} - 3.23 \cdot \text{Actividad_Fisica}$$

4.1 Interpretación de coeficientes

Por cada año adicional de edad, el nivel de glucosa aumenta en promedio 0.52 mg/dL. Por cada punto adicional de índice de masa corporal (IMC), la glucosa aumenta en promedio 1.92 mg/dL. La actividad física presenta un efecto protector: por cada hora semanal adicional de ejercicio, el nivel de glucosa disminuye en promedio 3.23 mg/dL. Al calcular la importancia relativa de cada variable (valor absoluto del coeficiente multiplicado por la desviación estándar de la variable, para hacerlas comparables en una misma escala), se obtuvo: IMC = 12.54, Actividad física = 11.69 y Edad = 8.53. Por lo tanto, el IMC es la variable con mayor impacto global sobre el nivel de glucosa, seguida muy de cerca por la actividad física.

4.2 Desempeño del modelo

Conjunto	MSE	RMSE	R ²
Entrenamiento	27.74	5.27	0.9296
Prueba	31.53	5.62	0.9352
Validación cruzada (5-fold)	—	—	0.9270 ± 0.0095

Tabla 6

Métricas de desempeño del modelo de Nivel_Glucosa

La diferencia entre el R² de entrenamiento y de prueba fue de -0.0056 , valor inferior al umbral de 0.05 establecido como criterio de sobreajuste, y el R² obtenido en la validación cruzada resultó consistente con ambos conjuntos. En consecuencia, el modelo generaliza adecuadamente y no presenta evidencia de sobreajuste, superando el umbral de $R^2 > 0.90$ exigido para el conjunto de prueba.

4.3 Visualización de relaciones entre variables

Figura 3
Relación de cada variable independiente con Nivel_Glucosa





Figura 4
Matriz de correlación — Predicción de niveles de glucosa en sangre



5. Predicción del consumo de energía eléctrica

Se ajustó un modelo de regresión lineal múltiple utilizando las variables independientes Temperatura, Hora del día y Día de la semana para predecir la variable Consumo_Energia. La ecuación del modelo resultante es la siguiente:

$$\text{Consumo_Energia} = 14.73 + 1.32 \cdot \text{Temperatura} + 0.89 \cdot \text{Hora} - 1.61 \cdot \text{Dia_Semana}$$

5.1 Interpretación de coeficientes

La importancia relativa de cada variable (valor absoluto del coeficiente multiplicado por su desviación estándar) fue: Temperatura = 16.98, Hora = 6.45 y Día de la semana = 3.33. La temperatura es, por un margen amplio, la variable con mayor impacto en el consumo eléctrico, lo cual es consistente con el uso de sistemas de climatización (calefacción o aire acondicionado) ante temperaturas extremas. La hora del día ocupa el segundo lugar en importancia, y el día de la semana presenta una influencia menor, aunque consistente con un menor consumo hacia el fin de semana.

5.2 Desempeño del modelo

Conjunto	MSE	RMSE	R ²
Entrenamiento	20.44	4.52	0.9424
Prueba	24.25	4.93	0.9340
Validación cruzada (5-fold)	—	—	0.9372 ± 0.0105

Tabla 7

Métricas de desempeño del modelo de Consumo_Energía

La diferencia entre el R² de entrenamiento y de prueba fue de 0.0084, valor inferior al umbral de 0.05 establecido como criterio de sobreajuste, y el R² obtenido en la validación cruzada resultó consistente con ambos conjuntos. En consecuencia, el modelo generaliza adecuadamente y no presenta evidencia de sobreajuste, superando el umbral de R² > 0.90 exigido para el conjunto de prueba.

5.3 Visualización de relaciones entre variables

Figura 5
Relación de cada variable independiente con Consumo_Energía





Figura 6
Matriz de correlación — Predicción del consumo de energía eléctrica



6. Resumen comparativo de los tres modelos

La Tabla 5 presenta un resumen comparativo del desempeño de los tres modelos desarrollados. En todos los casos el R^2 del conjunto de prueba superó el 90%, con una diferencia mínima frente al R^2 de entrenamiento y resultados consistentes en validación cruzada, lo que confirma que los modelos generalizan correctamente y no se encuentran sobreajustados.

Ejercicio	R ² Train	R ² Test	R ² CV (5-fold)	Diferencia Train-Test	¿Sobreajuste?
Dólar	0.9304	0.9132	0.9249 ± 0.0132	0.0172	No
Glucosa	0.9296	0.9352	0.9270 ± 0.0095	−0.0056	No
Energía	0.9424	0.9340	0.9372 ± 0.0105	0.0084	No

Tabla 5

Comparación del desempeño de los tres modelos de regresión lineal múltiple

7. Exportación de los modelos

Se investigaron las librerías *pickle* y *joblib* de Python para la serialización de modelos entrenados. Se optó por *joblib*, dado que scikit-learn la recomienda de forma oficial para objetos que contienen grandes arreglos de NumPy —como es el caso de los modelos de regresión lineal—, al ofrecer una compresión y velocidad de lectura/escritura más eficiente que *pickle* en estos escenarios (Pedregosa et al., 2011). Cada modelo se exportó junto con sus metadatos (variables independientes, variable dependiente y métricas de desempeño) en un único archivo: *modelo_dolar.pkl*, *modelo_glucosa.pkl* y *modelo_energia.pkl*, ubicados en la carpeta *models/* del proyecto.

8. Desarrollo de la interfaz web

Se desarrolló una interfaz web interactiva utilizando el framework Streamlit, la cual permite al usuario seleccionar uno de los tres ejercicios (Dólar, Glucosa o Energía), ingresar por teclado los valores de las variables independientes correspondientes y obtener de forma inmediata la predicción de la variable dependiente, junto con los indicadores de desempeño del modelo (R² y RMSE) y la posibilidad de consultar los coeficientes utilizados. La interfaz carga directamente los modelos previamente exportados, sin necesidad de reentrenamiento, lo que

permite su despliegue como una aplicación productiva independiente del proceso de modelado.

9. Conclusiones

- La metodología CRISP-DM permitió estructurar el desarrollo del laboratorio de forma ordenada, desde la comprensión del problema hasta el despliegue de un producto utilizable por un usuario final no técnico.
- Los tres modelos de regresión lineal múltiple lograron un ajuste satisfactorio (R^2 superior al 90% en el conjunto de prueba), sin evidencia de sobreajuste, gracias a la validación mediante conjuntos de prueba independientes y validación cruzada de cinco particiones.
- En el caso del precio del dólar, la inflación resultó ser la variable con mayor efecto marginal, mientras que la tasa de interés actúa en sentido contrario, resultado coherente con la teoría económica.
- En el caso del nivel de glucosa, el índice de masa corporal (IMC) fue la variable con mayor impacto global, seguida de cerca por la actividad física, la cual actúa como factor protector.
- En el caso del consumo de energía eléctrica, la temperatura fue la variable dominante, resultado consistente con el uso de sistemas de climatización.
- La exportación de los modelos mediante joblib y su integración en una interfaz web desarrollada con Streamlit permitió completar el flujo integral de un proyecto de minería de datos: desde el dato crudo hasta un modelo productivo, accesible e interpretable.

Referencias

- American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7.^a ed.). <https://doi.org/10.1037/0000165-000>
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to linear regression analysis* (6.^a ed.). Wiley.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.